

Reporte del Proyecto

Lennin

Proyecto Aurelion – Análisis Inteligente de Ventas

Fundamentos de Inteligencia Artificial — IBM SkillsBuild

Grupo 06

- **Curso:** Fundamentos de Inteligencia Artificial
 - **Camada:** 11 martes
 - **Docente:** Mirta Gladys Julio
 - **Fecha de entrega:** 09 de Noviembre de 2025
-

1.1 Tema, Problema y Solución

Tema

Aplicación de técnicas de análisis de datos e Inteligencia Artificial para la optimización estratégica de ventas mediante el análisis integrado de datos comerciales en la tienda Aurelion.

El proyecto “**Tienda Aurelion**” evidencia cómo el análisis de datos y la estadística aplicada pueden convertir una operación tradicional de ventas en una **gestión estratégica basada en datos**. Durante la primera etapa (Spring 1), se desarrolló un proceso completo de ingestión, limpieza, integración y enriquecimiento de datos, consolidando diversas fuentes en un único modelo analítico `df_master`. Esto permitió comprender el estado actual del negocio, identificar patrones clave y responder preguntas fundamentales relacionadas con ventas, clientes, productos y sucursales. En la segunda etapa (Spring 2), se incorporó un análisis estadístico exhaustivo con el fin de profundizar en el comportamiento de las variables numéricas y validar hallazgos mediante herramientas cuantitativas. Se aplicaron técnicas como estadística descriptiva, detección de

outliers, análisis de correlaciones, cálculo de intervalos de confianza y segmentación RFM. Estos análisis proporcionaron insights valiosos para la toma de decisiones estratégicas, permitiendo a la tienda Aurelion optimizar sus operaciones comerciales y focalizar esfuerzos en los segmentos de mayor valor.

Problema

La tienda Aurelion recopila una gran cantidad de datos sobre clientes, productos y ventas. Sin embargo, no cuenta con un sistema que permita analizarlos de forma integral, lo que genera los siguientes desafíos:

1. Desconocimiento del cliente

No se identifican patrones de compra, lo que impide reconocer a los clientes más valiosos y sus preferencias.

2. Estrategias de venta genéricas

Las campañas de marketing y promociones se aplican de forma uniforme, lo que reduce el retorno de inversión y genera oportunidades perdidas.

3. Ineficiencia operativa

Consultas básicas como “*¿Cuál fue el producto más vendido el mes pasado?*” requieren procesos manuales que consumen tiempo y recursos.

La empresa opera de forma **reactiva**, sin una estrategia basada en datos que le permita tomar decisiones proactivas para impulsar su crecimiento.

Solución

Implementar un **flujo de trabajo analítico automatizado en Python** que convierta los datos crudos en **información accionable**. Este flujo consta de tres etapas principales:

1. Consolidación de datos

Integración de las tablas Clientes, Productos, Ventas y Detalle de Venta en un único DataFrame maestro, generando una visión 360° del negocio.

2. Análisis descriptivo automatizado

Generación automática de respuestas a preguntas clave del negocio:

- Top 10 productos más vendidos (por cantidad e ingresos).
- Ranking de clientes más valiosos.
- Ventas por categoría y ciudad.
- Evolución mensual de ventas.

3. Base para modelos de IA

Este análisis servirá como punto de partida para futuras aplicaciones de Machine Learning, como la segmentación de clientes mediante algoritmos como K-Means.

Herramientas utilizadas:

- **Python:** `pandas`, `matplotlib`, `seaborn`
 - **GitHub Copilot:** Asistente de codificación para acelerar el desarrollo y sugerir soluciones eficientes en el manejo de datos.
-

1.2 Dataset de Referencia

Fuente

Los datos proporcionados por la cátedra en formato Excel (.xlsx), fueron expandidos y distribuidos en siete archivos:

- `clientes_expanded.xlsx`
- `productos_expanded.xlsx`
- `ventas_expanded.xlsx`
- `detalle_ventas_expanded.xlsx`
- `sucursales_expanded.xlsx`
- `vendedores_expanded.xlsx`
- `medios_pago_expanded.xlsx`

Descripción

El conjunto de datos representa un ecosistema de ventas minoristas, capturando las interacciones entre clientes, productos, sucursales y métodos de pago. Permite responder preguntas como:

- **¿Qué se vendió?** → Productos
- **¿Quién compró?** → Clientes

- **¿Cuándo?** → Fecha de la transacción
- **¿Dónde?** → Sucursal de la venta
- **¿Cómo?** → Medio de pago y cantidad adquirida

Escala del Dataset

Tabla	Registros
clientes_expanded	100
productos_expanded	100
ventas_expanded	720
detalle_ventas_expanded	2016
sucursales_expanded	6
vendedores_expanded	36
medios_pago_expanded	4

Modelo de Datos

Se emplea un **modelo estrella expandido**, compuesto por:

- **Tablas de dimensión** (describen entidades):
 - Clientes
 - Productos
 - Sucursales
 - Categorías
 - Métodos de Pago
 - **Tablas de hechos** (registran transacciones):
 - Ventas
 - Detalle de Venta
-

Estructura Detallada de las Tablas

A continuación se presenta la estructura de las tablas fuente y las columnas clave que se integran y utilizan en el `df_master`:

1. Tabla de Dimensión: clientes_expanded

Columna	Tipo de Dato	Descripción
id_cliente	int64	Identificador único (Clave Primaria)
nombre_cliente	object	Nombre y apellido del cliente
email	object	Dirección de correo electrónico
ciudad	object	Ciudad de residencia
fecha_alta	datetime64	Fecha de registro del cliente
genero	object	Género del cliente
edad_rango	object	Rango de edad del cliente
activo_como_cliente	bool	Estado de actividad del cliente

2. Tabla de Dimensión: productos_expanded

Columna	Tipo de Dato	Descripción
id_producto	int64	Identificador único (Clave Primaria)
nombre_producto	object	Nombre comercial del producto
categoria	object	Categoría a la que pertenece
precio_unitario	float64	Precio unitario de venta
subcategoria	object	Subcategoría del producto

3. Tabla de Dimensión: sucursales_expanded

Columna	Tipo de Dato	Descripción
id_sucursal	int64	Identificador único (Clave Primaria)
nombre_sucursal	object	Nombre de la sucursal
ciudad	object	Ciudad donde se encuentra
provincia	object	Provincia donde se encuentra

4. Tabla de Dimensión: medios_pago_expanded

Columna	Tipo de Dato	Descripción
id_medio_pago	int64	Identificador único (Clave Primaria)
nombre_medio_pago	object	Nombre del método de pago

5. Tabla de Dimensión: vendedores_expanded

Columna	Tipo de Dato	Descripción
id_vendedor	int64	Identificador único (Clave Primaria)
nombre_vendedor	object	Nombre del vendedor
id_sucursal	int64	Clave foránea a SUCURSALES
fecha_ingreso	datetime64	Fecha de ingreso del vendedor
activo	bool	Estado de actividad del vendedor

6. Tabla de Hechos: ventas_expanded

Columna	Tipo de Dato	Descripción
id_venta	int64	Identificador único (Clave Primaria)
fecha	datetime64	Fecha y hora de la venta
id_cliente	int64	Clave foránea a CLIENTES
id_sucursal	int64	Clave foránea a SUCURSALES
id_vendedor	int64	Clave foránea a VENDEDORES
id_medio_pago	int64	Clave foránea a MEDIOS_PAGO
nombre_cliente	object	Nombre del cliente (redundante)
email	object	Email del cliente (redundante)
medio_pago_original	object	Método de pago (texto original)
estado_venta	object	Estado de la venta
monto_bruto	float64	Monto total de la venta antes desc.
monto_neto	float64	Monto total de la venta después desc.

7. Tabla de Hechos: detalle_ventas_expanded

Columna	Tipo de Dato	Descripción
id_venta	int64	Clave foránea a VENTAS
id_producto	int64	Clave foránea a PRODUCTOS
nombre_producto	object	Nombre producto (redundante)
cantidad	int64	Número de unidades vendidas
precio_unitario	float64	Precio unitario al momento de venta
importe	float64	Cálculo: cantidad * precio_unitario
descuento_aplicado_pct	int64	% de descuento aplicado (0-100)
subtotal	float64	Importe con descuento aplicado

Nota: Después de la unificación, el DataFrame `df_master` contendrá columnas de todas estas tablas, renombradas donde sea necesario (ej. `nombre_producto_x`,

`precio_unitario_x` del detalle, `nombre_producto_y`, `precio_unitario_y` del producto, `ciudad_x` del cliente, `ciudad_y` de la sucursal, `id_sucursal_x` de ventas, `id_sucursal_y` de vendedores). También se agregan columnas de ingeniería de características como `año`, `mes`, `dia_nombre`, `descuento_pct` (`descuento_aplicado_pct / 100`), y `monto_final` (subtotal con descuento).

Notas: Los campos redundantes deben ignorarse o eliminarse en el análisis. Se usan solo los IDs para mantener la integridad referencial.

1.3 Información, Pasos, Pseudocódigo y Diagrama del Programa

Descripción del Funcionamiento

El programa es un script en Python que automatiza el proceso de análisis de datos de la tienda Aurelion. Realiza:

1. **Carga** de los 7 archivos Excel.
2. **Limpieza** de datos (nulos, duplicados, tipos de datos).
3. **Unificación** en una tabla maestra (`df_master`).
4. **Ingeniería de características** (extracción de año, mes, día de semana).
5. **Análisis descriptivo** de 6 preguntas de negocio.
6. **Visualización** de resultados mediante gráficos.

Finalmente, presenta los resultados en consola y gráficos, sirviendo como base para decisiones estratégicas.

Pasos del Desarrollo

1. **Cargar y Consolidar Datos:** Uso de `pandas.read_excel()` para cargar los archivos. Limpieza y unión de tablas mediante `merge()`.
2. **Limpieza y Conversión:** Asegurar tipos de datos correctos, especialmente para fechas. Verificar y manejar (aunque en este dataset no hubo) valores nulos.
3. **Ingeniería de Características:** Crear columnas derivadas (`año`, `mes`, `dia_nombre`, `descuento_pct`, `monto_final`).
4. **Análisis Estadístico Básico y Avanzado:** Calcular estadísticas descriptivas, identificar distribuciones, analizar correlaciones (Pearson y Spearman), detectar outliers (IQR, Z-score) y calcular intervalos de confianza.
5. **Análisis de Negocio Específico:** Realizar análisis RFM de clientes, análisis de ingresos por producto y análisis temporal de ventas.

6. **Visualización de Resultados:** Generar gráficos relevantes (histogramas, box plots, violin plots, heatmaps, scatter plots, bar plots, series de tiempo).
7. **Interpretación y Documentación:** Consolidar hallazgos, interpretarlos en el contexto del negocio y documentar el proceso y los resultados.

Pseudocódigo (Completo)

```

dame el codigo para seinpt : INICIO_PROGRAMA

// =====
// PASO 1: CONFIGURACIÓN DEL ENTORNO
// =====
IMPORTAR librerías necesarias:
    - pandas
    - matplotlib
    - seaborn
    - numpy (opcional para operaciones estadísticas)

// =====
// PASO 2: CARGA DE DATOS
// =====
CARGAR los siguientes DataFrames desde archivo o ruta:
    - clientes_expanded
    - productos_expanded
    - ventas_expanded
    - detalle_ventas_expanded
    - medios_pago_expanded
    - sucursales_expanded
    - vendedores_expanded

// =====
// PASO 3: EXPLORACIÓN Y LIMPIEZA DE DATOS
// =====
PARA cada tabla EN la lista de DataFrames:
    MOSTRAR columna, tipos de datos y valores nulos
    SI existen valores nulos:
        APlicAR estrategia de limpieza (rellenar, eliminar filas, etc.)
    SI existen duplicados:
        ELIMINAR duplicados si corresponde
FIN PARA

```

```

CONVERTIR columnas de fechas (fecha, fecha_alta, fecha_ingreso) al tipo datetime

// =====
// PASO 4: MODELADO Y UNIÓN DE LOS DATOS
// =====
// Se realizarán las uniones necesarias para formar un DataFrame maestro

UNIR detalle_ventas_expanded CON productos_expanded mediante id_producto  df_dv_prod
UNIR df_dv_prod CON ventas_expanded mediante id_venta  df_ventas_completas
UNIR df_ventas_completas CON clientes_expanded mediante id_cliente  df_vtas_clientes
UNIR df_vtas_clientes CON sucursales_expanded mediante id_sucursal  df_vtas_sucursal
UNIR df_vtas_sucursal CON vendedores_expanded mediante id_vendedor  df_vtas_vendedor
UNIR df_vtas_vendedor CON medios_pago_expanded mediante id_medio_pago  df_master

// df_master contendrá ahora información consolidada de cliente, producto, venta, sucursal, ...

// =====
// PASO 5: INGENIERÍA DE CARACTERÍSTICAS (FEATURE ENGINEERING)
// =====

CREAR nuevas columnas:
- Año de venta (a partir de fecha)
- Mes de venta
- Día de la semana
- Rango_etario_categorizado (opcional, basado en edad_rango)
- Descuento_aplicado_pct_categorizado (segmentar nivel de descuentos)
- Monto_final = subtotal - (subtotal * descuento_aplicado_pct)

// =====
// PASO 6: ANÁLISIS DE DATOS Y MÉTRICAS CLAVE
// =====

// ANÁLISIS DE PRODUCTOS
CALCULAR: Productos más vendidos (por cantidad total)
CALCULAR: Productos con mayor facturación (por subtotal o monto_final)
CALCULAR: Categorías y subcategorías más populares

// ANÁLISIS DE CLIENTES
CALCULAR: Clientes que más compran (por monto_total)
CALCULAR: Distribución por género, ciudad, edad
CALCULAR: Clientes inactivos vs activos

// ANÁLISIS DE VENTAS

```

```

ANALIZAR: Evolución de ventas por mes
ANALIZAR: Días de la semana con mayor volumen de ventas
ANALIZAR: Comparativa monto_bruto vs monto_neto, con descuentos

// ANÁLISIS DE SUCURSALES Y VENDEDORES
CALCULAR: Ranking sucursales por ingresos
CALCULAR: Vendedores con mayor volumen de ventas
CALCULAR: Productividad media por vendedor

// ANÁLISIS DE MEDIOS DE PAGO
CALCULAR: Proporción de medios de pago utilizados

// ANÁLISIS ESTADÍSTICO AVANZADO
CALCULAR: Estadísticas descriptivas (media, mediana, moda, desviación estándar)
CALCULAR: Recencia, Frecuencia, Valor Monetario para cada cliente
SEGMENTAR: Clientes en grupos RFM (Top, Medio, Bajo)
CALCULAR: Distribución de variables numéricas (skewness, kurtosis)
CALCULAR: Correlaciones (Pearson, Spearman) entre variables numéricas
DETECTAR: Outliers mediante IQR y Z-score
CALCULAR: Intervalos de confianza para montos de venta

// =====
// PASO 7: VISUALIZACIONES Y TABLEROS
// =====
GENERAR gráficos:
    - Barras horizontales (Top productos, Top clientes)
    - Histograma (distribución medios de pago, productos por categoría)
    - Serie de tiempo (ventas por mes)
    - Calor o heatmap (ventas por sucursal y mes)
    - Boxplot (variables numéricas distribución y outliers)
    - Violin plot (variables numéricas distribución y outliers)
    - rfm scatter plot (segmentación RFM)

// =====
// FIN DEL PROGRAMA
// =====
FINALIZAR_PROGRAMA

```

Diagrama de Flujo (Resumen Visual)

Nota: El diagrama completo fue generado en PSeInt y se adjunta como imagen en el documento original. A continuación se presenta su estructura lógica:

1.4 Sugerencias y Mejoras Aplicadas con GitHub Copilot

Sugerencias Aceptadas

Sugerencia	Beneficio
Autocompletado de operaciones <code>groupby().sum().sort_values()</code>	Aceleró la creación de análisis de agregación.
Generación de plantillas de gráficos con <code>sns.barplot(), plt.title()</code>	Permitió centrarse en personalización estética.
Sugerencias de manejo de fechas con <code>pd.to_datetime()</code>	Mejoró la precisión en el análisis temporal.

Sugerencias Descartadas

Sugerencia	Razón de Rechazo
Uso de <code>lambda</code> o <code>list comprehensions</code> complejas para filtrado	Reducía legibilidad; se prefirió <code>.loc[]</code> y métodos explícitos de Pandas.
Implementación de K-Means para segmentación de clientes	Fuera de alcance: en esta etapa el proyecto es de análisis descriptivo , no predictivo.

1.5 Programa en Python (Implementación en Jupyter Notebook)

Archivo: Proyecto_Aurelion_S2.ipynb

Funcionalidad

El programa se implementa como un **Jupyter Notebook**, no como un script de consola. Esto permite:

- Documentar cada paso con **celdas Markdown** (explicaciones).
- Ejecutar **celdas de código individualmente** (Shift + Enter).
- Ver resultados **en línea** (tablas, gráficos, resúmenes).

Interacción del Usuario

1. Leer la documentación en celdas Markdown.
2. Ejecutar celdas de código en orden.
3. Observar resultados inmediatos:
 - `df.head()`
 - `df.info()`
 - Gráficos integrados con `matplotlib/seaborn`.

Ventajas del script Notebook Jupyter

Ventaja	Descripción
Narrativa	El notebook cuenta una historia: “de los datos a la decisión”.
Reproducibilidad	Cualquier persona puede ejecutarlo paso a paso.
Exploración	Ideal para validación, ajustes y presentaciones académicas.
Documentación	Todo el análisis está registrado y explicado.

SPRING 2

Desarrollo de aplicación de técnicas estadísticas:

1. Base de datos limpia y lista
2. Calcular estadísticas básicas calculadas
3. Identificar tipo de distribución de variables
4. Análisis de correlaciones entre variables principales
5. Detección de outliers mediante curatiles y rangos
6. Interpretar resultados para el problema de negocio
7. Documentar

Resumen Consolidado del Análisis Estadístico - Spring 2

Este informe presenta los hallazgos clave del análisis estadístico, realizado sobre el dataset unificado `df_master` generado en el Spring 1, con el objetivo de comprender el comportamiento comercial mediante estadísticas descriptivas, identificación de outliers, correlaciones, intervalos de confianza, segmentación RFM, análisis de productos e interpretación temporal de ventas. Logrando construir una visión integral del negocio, automatizar procesos analíticos y generar insights relevantes para la toma de decisiones comerciales.

Logros destacados

Dimensión	Resultado
Consolidación de datos	Integración completa de 7 fuentes en un DataFrame maestro de 2016 registros
Estadística descriptiva	Identificación clara de rangos, variabilidad y distribución de variables clave
Análisis avanzado	Detección de outliers, correlaciones, intervalos de confianza y segmentación RFM
Modelado de clientes	Clasificación estadística de ** clientes activos** en cinco segmentos de valor

1. Estadísticas Descriptivas

El análisis descriptivo permitió caracterizar las principales variables numéricas. Se identificó alta variabilidad en las variables monetarias, así como distribuciones sesgadas hacia la derecha, indicando que pocas transacciones de alto valor explican gran parte de los ingresos. En contraste, las variables `cantidad` y `precio_unitario_x` muestran mayor estabilidad y simetría.

Indicadores Descriptivos Relevantes

Indicador	Resultado	Interpretación
Coeficiente de variación en montos	> 50%	Alta dispersión: las ventas presentan variabilidad considerable entre transacciones.

Indicador	Resultado	Interpretación
Sesgo (Skewness) en montos	> 0.5	Sesgo positivo: predominan ventas de bajo valor con presencia de operaciones de alto importe.
Variables más estables	Cantidad y precio unitario	Distribución más homogénea y sin variaciones extremas significativas.

Comportamiento de las ventas

Métrica	Valor
Ticket promedio por detalle	\$83.86
Rango estimado (IC 95%)	\$81.48 – \$86.24
Cantidad promedio por ítem	2.68 unidades
Precio unitario promedio	\$31.45

Las ventas unitarias son estables, con valores influenciados tanto por cantidad como por precio del producto.

Interpretación de Distribuciones Numéricas

Las visualizaciones (Boxplot + Violin Plot) confirman patrones clave en las variables numéricas:

- Las variables monetarias muestran **fuerte sesgo positivo**, típico en ventas: muchas transacciones pequeñas y pocas de alto valor.
- **descuento_aplicado_pct** presenta distribución **altamente sesgada y concentrada en 0**, reflejando uso poco frecuente del descuento.
- **cantidad y precio_unitario_x** exhiben distribuciones más **estables y sin outliers relevantes** bajo IQR.

Estas formas de distribución respaldan las estadísticas descriptivas y guían decisiones de preparación de datos y selección de técnicas analíticas.

2. Detección de Outliers

Para identificar valores atípicos se aplicaron los métodos **IQR** y **Z-score**, enfocándonos en detectar transacciones inusuales y comportamientos anómalos en descuentos.

Variable	% Outliers	Observación
Cantidad	0%	No se observan cantidades fuera del comportamiento esperado.
Precio Unitario	0%	Los precios se mantienen dentro del rango normal de variación.
Variables monetarias	0.40% – 0.50%	Pocas transacciones excepcionalmente altas, asociadas a compras grandes.
Descuento aplicado	15.23% (307 casos)	El descuento es poco frecuente y en proporciones específicas.

Interpretación: Los valores monetarios muestran casos aislados de transacciones grandes, consistentes con ventas puntuales de alto valor. La mayoría de los outliers corresponde a la variable de descuento, indicando que solo se aplica en situaciones muy particulares y con baja recurrencia.

3. Correlación entre Variables

Mapa de Calor de Correlaciones

Las correlaciones muestran relaciones clave entre las métricas comerciales, principalmente entre valores monetarios y cantidades vendidas.

Relación	Coeficiente	Interpretación
Cantidad Importe	0.71	A mayor cantidad comprada, mayor importe de la venta.
Precio Unitario Importe	0.63	Precios más altos tienden a generar tickets de mayor valor.

Relación		Coefficiente	Interpretación
Importe	Monto Final	0.99	El monto final prácticamente coincide con el importe calculado.
Monto Bruto	Monto Neto	1.00	No existen diferencias entre monto bruto y neto (sin descuentos).

Conclusión: Las relaciones monetarias son altamente consistentes, mientras que la cantidad y el precio unitario influyen significativamente pero no determinan por completo el valor total de la venta.

4. Intervalos de Confianza (95%)

Monto final por detalle de venta: - Media: \$82.06
- IC 95%: \$79.71 — \$84.41

Los intervalos estiman con precisión las verdaderas medias poblacionales de las principales métricas.

5. Segmentación RFM

La segmentación RFM permitió clasificar a los clientes según su **recencia, frecuencia y monto gastado**, identificando los grupos más valiosos para el negocio.

Segmento	% Clientes	% Ingresos	Ticket Promedio
Champions	24%	55%	\$3,794.95
Loyal	23%	21%	\$1,481.52
Potential	21%	14%	\$1,084.05
At Risk	15%	6%	\$705.59
Lost	16%	4%	\$433.59

> **Interpretación:** Los segmentos Champions y Loyal, que representan cerca del 47% de la base de clientes, generan más del 75% de los ingresos. Estos grupos deben ser prioritarios en estrategias de fidelización, retención y ofertas personalizadas.

6. Análisis de Ingresos por Producto

El análisis de ingresos por producto reveló que un pequeño grupo de productos contribuye significativamente a los ingresos totales.

Producto	Total Ingresos
Sprite 1.5L	\$4,269.04
Empanadas Congeladas	\$3,057.92
Desodorante Ambiente Aerosol	\$3,048.50
Pizza Congelada Muzzarella	\$2,914.48
Pepsi 1.5L	\$2,735.15

Bebidas y congelados lideran la venta total y por ticket.

7. Análisis Temporal de Ventas

El comportamiento de las ventas a lo largo del tiempo muestra una dinámica estable, sin patrones estacionales pronunciados:

- Se observan fluctuaciones semanales normales, sin cambios estructurales en la tendencia general.
- La distribución mensual de los importes no presenta variaciones significativas entre periodos.
- La prueba estadística Kruskal-Wallis ($p = 0.3878$) confirma la **ausencia de estacionalidad relevante**, indicando que el comportamiento de las ventas no depende significativamente del mes, sujeta a revisión.

Conclusión: El flujo de ventas parece mantener estabilidad, lo que sugiere una demanda constante, pudiendo estar influenciada por factores externos no capturados en el dataset actual.

Conclusiones Generales

- Estabilidad en el comportamiento temporal de las ventas, sin estacionalidad significativa.
- Alta concentración del valor generado en un grupo reducido de clientes y productos estratégicos.
- Relevancia de monitorear descuentos y transacciones atípicas para garantizar control y consistencia en las ventas.
- Enfoque prioritario en clientes de alto valor para maximizar la rentabilidad y fomentar la fidelización.
- Toma de decisiones respaldada por evidencia estadística y análisis riguroso.
- Identificación clara de segmentos y líneas de producto clave para acciones comerciales dirigidas.
- Base sólida para el desarrollo de modelos predictivos y estrategias de crecimiento orientadas a datos.

Próximos Pasos

Enfoque	Acciones propuestas
Predicción	Modelos de <i>forecasting</i> para proyección de ventas; <i>Churn prediction</i> utilizando modelos supervisados (Logistic Regression, Random Forest, XGBoost) para anticipar pérdida de clientes.
Segmentación Avanzada	Extender análisis RFM con <i>clustering</i> (K-Means, DBSCAN) para identificar microsegmentos de clientes y patrones no visibles con reglas tradicionales.
Marketing Personalizado	Campañas orientadas a segmentos clave con estrategias diferenciadas: retención (Champions, Loyal), reactivación (At-Risk, Lost).
Control de Descuentos	Implementar reglas dinámicas y análisis de sensibilidad del descuento (<i>price elasticity</i>).
Detección de Anomalías	Aplicar modelos de <i>anomaly detection</i> (Isolation Forest, Z-score dinámico) para identificar transacciones inusuales o fraudes.
Visualización y Reporting	Construcción de dashboard ejecutivo (Power BI / Streamlit) con alertas automáticas y seguimiento de KPIs clave.
Automatización	Pipeline de actualización automática de datos y reportes programados.

Objetivo central: evolucionar de análisis descriptivo a **análisis predictivo y prescriptivo**, aplicacando las mejores acciones propuestas para fortalecer la toma de decisiones basada en datos y potenciando el crecimiento del negocio.